



# Curso de Fatores

*Fatores Multiplicativos Fundamentados*

Luiz Droubi

Academia da Engenharia de Avaliações



25 de julho de 2025

# Índice

- Introdução
- Origem dos Fatores Multiplicativos
- Utilização de Fatores Multiplicativos
- Centralização de Dados
- Múltiplos Fatores Multiplicativos
- Exemplo 1
- Outros tipos de variáveis explicativas
- Exemplo 2
- Paradoxo de Simpson
- Exemplo 3



# Introdução



# Sobre a arte de comunicar

Comunicação não é o que você fala, é o que o outro entende!

- O Tratamento Científico trouxe **consistência** para a Engenharia de Avaliações
- O Tratamento por Fatores, contudo, não deixou de ser utilizado
  - Acredita-se que, em parte, isso se deve à clareza obtida com este tipo de tratamento
- A consistência alcançada com o Tratamento Científico deu-se a custa de uma perda na clareza da comunicação
- É possível conciliar?
  - Trivelloni (2005);
  - Cerino et al. (2020);
  - Droubi, Zilli, e Hochheim (2021);
  - Droubi e Florencio (2024) e Oliveira, Bandeira, e Távora (2024)



# Sobre a necessidade de Fatores

- Há outra utilidade, além da clareza, na utilização do tratamento por fatores?
- Na confecção de Plantas de Valores Genéricos (PVG):
  - Ao elaborar PVG por face de quadra:
  - Na fase de avaliação, ajustamos um modelo de regressão linear
  - Depois, prevemos valores para os lotes paradigmata em cada face de cada quadra (e.g.  $12 \times 36 m^2$ )
  - Porém, esta PVG precisa ser utilizada para prever valores dos lotes reais da cidade, que tem características que podem ser diferentes das do lote paradigmata
  - Ao calcular o valor dos lotes reais, precisamos ajustar os valores de face de quadra para as características reais dos lotes
  - Ao comunicar à população o motivo das diferenças nas avaliações de cada imóvel, os fatores são uma boa pedida



# Sobre a necessidade de Fatores

- Nas avaliações pontuais:
  - Ao realizar uma avaliação imobiliária, nos deparamos com variáveis incompletas, mas que deveriam ser utilizadas. Por exemplo:
    - A elasticidade das ofertas em relação aos preços, nas avaliações imobiliárias em geral, urbanas ou rurais;
    - O andar em que se situa o imóvel, na avaliação de um apartamento;
    - A pedologia do solo, ao avaliar um lote para construção/incorporação.
- Que bom seria se sempre tivéssemos informações completas e claras sobre os imóveis
  - Mas então não precisaríamos de avaliadores!



# Origem dos Fatores Multiplicativos

# Qual a origem dos fatores multiplicativos?

- A utilização de fatores multiplicativos parece ser mais intuitiva do que a aplicação de fatores aditivos
- Ao colocar o seu imóvel à venda é natural comparar o seu imóvel a um imóvel parecido que tenha sido recentemente vendido
- Se um apartamento foi vendido no seu prédio, com características praticamente idênticas às do seu apartamento
  - Imaginemos que essa venda tenha se dado ao valor de mercado do apartamento
  - Qual a oferta mínima pelo seu apartamento você estaria disposto a aceitar?



# Qual a origem dos fatores multiplicativos? (2)

- Comparando com o apartamento do seu vizinho, você faz as seguintes observações:
  - O seu apartamento situa-se numa posição mais privilegiada no edifício
    - Por exemplo, uma posição solar mais favorável
    - Ou um andar mais alto
- Um apartamento situado em uma fachada mais favorável (ou em um andar mais alto) deve ter um valor um pouco superior a um apartamento com as mesmas características, porém situado em uma fachada desfavorável (ou em um andar mais baixo).
  - O quanto superior é que são elas!!!



# Qual a origem dos fatores multiplicativos? (3)

- Se pensarmos em R\$ 20.000,00 a mais por um apartamento de mesmas características, porém situado numa fachada mais favorável, isto é pouco ou é muito?
  - Se o valor de venda do apartamento similar foi R\$ 200.000,00, então isto equivale a 10,0% a mais, o que é relevante;
  - Porém, se o valor de venda do apartamento similar foi R\$ 2.000.000,00, R\$ 20.000,00 é praticamente insignificante (1,0%)!
- Se pensarmos em um valor 10% maior para um apartamento de mesmas características, porém em situação mais privilegiada, temos:
  - Apartamento de R\$ 200.000,00: R\$ 20.000,00 a mais!
  - Apartamento de R\$ 500.000,00: R\$ 50.000,00 a mais!
  - Apartamento de R\$ 900.000,00: R\$ 90.000,00 a mais!



# Qual a origem dos fatores multiplicativos? (3)

- Se olharmos pela ótica do comprador, a situação é ainda mais clara?
  - Se você está procurando um apartamento para comprar e se depara com duas oportunidades:
    - Um apartamento ao preço de R\$ 200.000,00;
    - Outro apartamento no mesmo edifício, porém em posição mais favorável, por R\$ 220.000,00;
    - A sua escolha irá depender da sua preferência!
    - Ambos os apartamentos estão corretamente precificados



# Qual a origem dos fatores multiplicativos? (4)

- Porém, se você se depara com duas ofertas:
  - Um apartamento ao preço anunciado de R\$ 2.000.000,00;
  - Outro ap. no mesmo edifício, em posição mais favorável, por R\$ 2.020.000,00;
  - Obviamente você irá optar pelo segundo, pois a diferença de preço é mínima e, por apenas 1% a mais você poderá desfrutar de um apartamento melhor
    - Os apartamentos não estão bem precificados
- Numa negociação, é comum a situação:
  - Oferta de R\$ 1,8 mi pelo ap. situado em posição solar desfavorável;
  - E justificar a proposta assim:
    - “Tem um apartamento ao lado, com fachada norte, por R\$ 2.020.000,00.”
  - A questão é que o preço do melhor é que pode estar com desconto
    - Por isso precisamos de avaliadores!



# Qual a origem dos fatores multiplicativos? (5)

- Se eu estou certo, um *Fator posição solar* deverá se apresentar na forma:

- $$F_{PS} = \frac{PS_i}{PS_{paradigma}} = \begin{cases} 1,0 & \text{se } PS_i = \text{Neutra} \\ 1,1 & \text{se } PS_i = \text{Favorável} \\ 0,9 & \text{se } PS_i = \text{Desfavorável} \end{cases}$$

- Se o valor de mercado de um apartamento numa fachada neutra é R\$ 1.000.000,00
  - Então o valor de um apartamento similar, porém em fachada favorável será:

- $P_i = \bar{P}_{Hom} \cdot F_{PS} = 1.000.000,00 \cdot 1,1 = \text{R\$}1.100.000,00$



# Utilização de Fatores Multiplicativos



# Como utilizar fatores multiplicativos

- Para homogeneizar valores (Lima 2006):

- 

$$P_{Hom_i} = \frac{P_{Obs_i}}{F_{1i} \cdot F_{2i} \cdot \dots \cdot F_{ki}} \quad (1)$$

- Exemplo:

- Um imóvel  $i$  da amostra conta com área e frente diferentes do avaliado
    - Primeiro precisamos homogeneizar este elemento em relação ao avaliado:
      -
    - Então, uma vez efetuada a homogeneização, todos os valores homogeneizados serão utilizados para o cômputo de um  $\overline{PU}_{Hom}$ , que será utilizado para estimar o valor de mercado do avaliado



# Como utilizar fatores multiplicativos

- Para prever valores (Lima 2006):

$$\blacksquare \hat{P}_i = \bar{P}_{Hom} \cdot F_{1i} \cdot F_{2i} \cdot \dots \cdot F_{ki} \quad (2)$$



# Fator Área de Abuhnaman

- Fator área de Abuhnaman (adaptado):

$$F_A = \left( \frac{A_i}{A_{paradigma}} \right)^{-1/4}$$

- Exemplo:

- $A_{paradigma} = 360m^2$
- $A_i = 400m^2$
- $P_i = \text{R\$ } 500.000,00$
- $F_{Ai} = \left( \frac{400}{360} \right)^{-1/4} \approx 0,9306$
- $P_{Hom_i} = P_i / F_{Ai} = 500.000,00 / 0,9306 = \text{R\$ } 537.285$ 
  - Se a área do imóvel fosse igual a  $360m^2$ , então seu preço seria maior!
- Também é um fator multiplicativo!
  - De onde vem isto?





<http://www.valoristica.com.br>

# Qual a origem dos fatores multiplicativos?




Figura 1: Resíduos vs. valores ajustados para um modelo aditivo.



# Cobb-Douglas

- Na econometria é muito conhecida a Função de *Cobb-Douglas*

- Na sua forma mais simples:

- 

$$Y = a \cdot X^b$$

- É possível linearizar a função de *Cobb-Douglas*:

- $\ln(Y) = \ln(a) + b \cdot \ln(X)$

- O que torna fácil estimar a regressão:

- $\ln(Y) = \beta_0 + \beta_1 \cdot \ln(X) + \varepsilon$

- Uma vez estimado o modelo de regressão acima, pode-se obter  $\hat{a}$  e  $\hat{b}$ :

- $\hat{a} = \exp(\hat{\beta}_0); \hat{b} = \hat{\beta}_1$
- $Y = \hat{a}X^{\hat{b}}$



## Cobb-Douglas (2)

- A linearização está centrada na hipótese de que o erro  $\xi$  é **multiplicativo**:

- $$Y = \hat{a}X^{\hat{b}} \cdot \xi$$
- $$\xi = \exp(\hat{\epsilon}) = \frac{Y}{\hat{a}X^{\hat{b}}} = \frac{Y}{\hat{Y}}$$



- Explicação:

$$\begin{aligned}\ln(Y) &= \ln(\hat{a}) + b \cdot \ln(X) + \hat{\epsilon} \\ \exp[\ln(Y)] &= \exp[\ln(a) + b \cdot \ln(X) + \hat{\epsilon}] \\ Y &= \exp[\ln(\hat{a})] \cdot \exp[b \cdot \ln(X)] \cdot \exp(\hat{\epsilon}) \\ Y &= \hat{a} \cdot X^{\hat{b}} \cdot \exp(\hat{\epsilon}) \\ \exp(\hat{\epsilon}) &= \frac{Y}{\hat{a} \cdot X^{\hat{b}}}\end{aligned}$$



# Cobb-Douglas (3)

- A hipótese de que o erro é aditivo pode não ser verificada no mercado imobiliário:




Termo de erro aditivo.




# Cobb-Douglas (4)

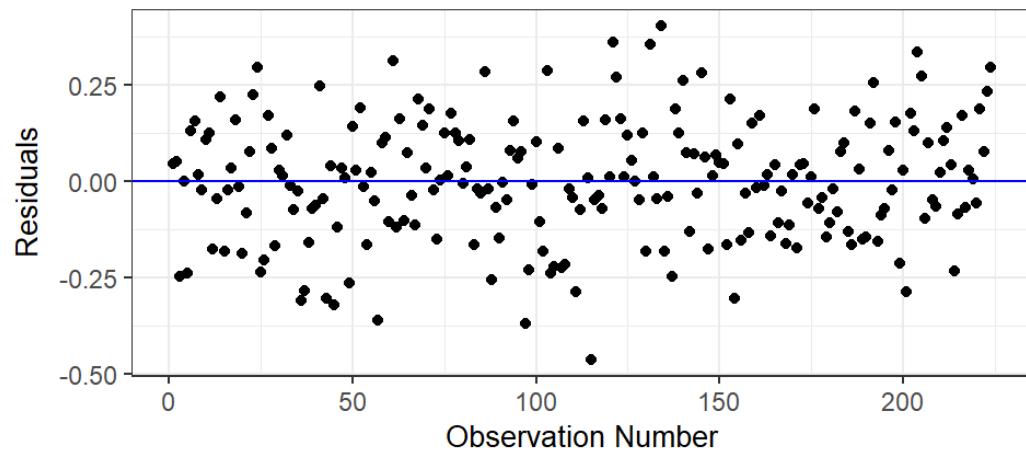
Residual Plot




Q-Q Plot



Index Plot



Histogram




Termo de erro multiplicativo

- A hipótese dos erros multiplicativos parece mais adequada!



# Cobb-Douglas (5)


Modelo Linear e Modelo Não-Linear



Dados para exemplificar a equação de Cobb-Douglas.



# Cobb-Douglas (6)



- $a = \exp(10,4) \approx 32.860,00; b \approx -0,25$
- $PU = 32.860,00 \cdot Area^{-0,25}$



# Centralização de Dados



# Justificativa

- O valor de  $\hat{\beta}_0$  não apresenta significado físico:
  - Não existe lote com  $0m^2$  de área
- A equação de estimação, portanto, fica com a interpretação um tanto prejudicada
- Isto pode ser contornado facilmente, contudo.
  - Basta centralizar a variável explicativa em relação à suas média (ou ao valor do imóvel avaliado)
    - Por exemplo, se o lote avaliado apresenta área de ( $360m^2$ )
    - No exemplo acima, se ao invés de utilizarmos a área do lote como variável explicativa, utilizarmos a área do lote dividida por 360, teremos:
    - $$\ln(PU) = \beta_0 + \beta_1 \cdot \ln(Area/360) + \epsilon$$



## Justificativa (2)


- $\ln(PU) = \beta_0 + \beta_1 \cdot \ln(Area/360) + \epsilon$ 
  - Assim, quando a área do lote for igual a  $360m^2$ , então:
    - $\ln(Area/360) = \ln(360/360) = \ln(1) = 0$
    - $\widehat{PU} = \hat{\beta}_0$ , ou seja,  $\hat{\beta}_0$  irá representar  $\widehat{PU}$  de um lote com  $360m^2$  de área
- Em termos estatísticos, tanto faz utilizar uma variável explicativa  $x$  ou uma transformação linear ( $x_{center} = (x - a)/b$ ) dela
  - De fato, é muito comum entre os estatísticos fazer, para cada  $X_i$ :
    - $$X_{ic} = \frac{X_i - \bar{X}_i}{SD(X_i)}$$
    - Isto é conhecido como padronização de variáveis!
  - $R^2$  será o mesmo, os  $\hat{\beta}_i$  serão os mesmos, apenas  $\hat{\beta}_0$  se modifica





<http://www.valoristica.com.br>

# Cobb-Douglas (7)



- $a = \exp(8.93) \approx 7.560,00; b \approx -0,25$
- $PU = 7.560 \cdot \left(\frac{Area}{360}\right)^{-0,25} = 7.560 \cdot \left(\frac{360}{Area}\right)^{+0,25}$



# Derivação do Fator Área

- $$PU = 7.560 \cdot \left( \frac{360}{Area} \right)^{+0,25} \quad (3)$$

- Com o modelo da Equação 3 é fácil derivar:
  - O fator área ( $F_S$ ):

- $$F_S = \left( \frac{360}{Area} \right)^{0,25}$$

- É fácil ver que:
  - Quando  $Area = 360m^2$ ,  $F_S = 1$
  - Quando  $Area > 360$ , então  $F_S < 1,0$
  - Quando  $Area < 360$ , então  $F_S > 1,0$

- $\overline{PU}_{Hom} = \exp(\hat{\beta}_0)$  (se a variável explicativa estiver centralizada!)





<http://www.valoristica.com.br>

# Aplicação do Fator Área

- Para homogeneização:
  - Imóvel da amostra com  $440m^2$  e  $PU = \text{R\$ } 7.000/m^2$ :
    - $F_S = (360/440)^{0,25} \approx 0,95$
    - $PU_{Hom} = 7.000/0,95 \approx \text{R\$ } 7.368,00/m^2$
- Para a avaliação:
  - Imóvel avaliado com  $250m^2$ , em amostra com  $\overline{PU}_{Hom} = 7.560$ :
    - $F_S = (360/250)^{0,25} = 1,0955$
    - $PU_{aval} = 7.560 \cdot 1,0955 \approx 8.280,00$



# Múltiplos Fatores Multiplicativos



# Cobb-Douglas

- É muito bem difundida entre os economistas a seguinte função de produção de Cobb-Douglas:
  - $Q(L, K) = A \cdot L^\beta \cdot K^\alpha$ 
    - $A > 0$  é uma constante
    - $L$  é o fator Trabalho
    - $K$  é o fator capital
    - $\alpha$  e  $\beta$  são coeficientes que dependem da indústria
    - $Q$  é a quantidade produzida, função de  $L$  e  $K$
- Como fazem os economistas para estimar  $A$ ,  $\alpha$  e  $\beta$ :

$$\ln(Q) = \ln(A \cdot L^\beta \cdot K^\alpha)$$

- - $\ln(Q) = \ln(A) + \ln(L^\beta) + \ln(K^\alpha)$
  - $\ln(Q) = \ln(A) + \beta \ln(L) + \alpha \ln(K)$



# Cobb-Douglas

- Da mesma forma, portanto, temos um modelo de regressão do tipo:

$$\ln(\widehat{PU}) = \hat{\beta}_0 + \hat{\beta}_1 \ln(L) + \hat{\beta}_2 \ln(K)$$

- Uma vez estimados  $\hat{\beta}_0, \hat{\beta}_1$  e  $\hat{\beta}_2$ , temos:

- $A = \exp(\hat{\beta}_0)$
- $\beta = \hat{\beta}_1$
- $\alpha = \hat{\beta}_2$



# Derivação de Fatores em Modelos RLM


- Nos modelos multiplicativos de regressão linear múltipla (**RLM**), temos:
  - $\ln(PU) = \beta_0 + \beta_1 \ln(X_1) + \beta_2 \ln(X_2) + \dots + \beta_k \ln(X_k) + \varepsilon$
- Centralizando estes modelos, teremos:
  - $\ln(PU) = \beta_0^* + \beta_1 \ln\left(\frac{X_1}{c_1}\right) + \beta_2 \ln\left(\frac{X_2}{c_2}\right) + \dots + \beta_k \ln\left(\frac{X_k}{c_k}\right) + \varepsilon$
- Estimando o modelo da equação acima, obtemos a eq. de Estimação:
  - $\widehat{PU} = \exp(\hat{\beta}_0^*) \cdot (X_1/c_1)^{\hat{\beta}_1} \cdot (X_2/c_2)^{\hat{\beta}_2} \cdot \dots \cdot (X_k/c_k)^{\hat{\beta}_k} \cdot \exp(\varepsilon)$
- $\overline{PU}_{Hom} = \exp(\hat{\beta}_0^*)$
- $F_1 = (X_1/c_1)^{\hat{\beta}_1}$
- $F_2 = (X_2/c_2)^{\hat{\beta}_2}$
- $\dots$
- $F_k = (X_k/c_k)^{\hat{\beta}_k}$





<http://www.valoristica.com.br>

# Exemplo 1




# Dados

- Zeni (2024):


<b>Id</b>	<b>A</b>	<b>D</b>	<b>PU</b>
1	2.500	1.800	140,00
2	2.800	450	255,00
3	3.500	1.000	180,00
4	4.350	650	228,00
5	5.980	820	152,30
6	6.650	1.250	134,50
7	7.700	1.350	115,00
8	8.120	980	128,75
9	9.520	840	143,10
10	10.410	1.140	114,25
11	11.000	500	157,50

<b>Id</b>	<b>A</b>	<b>D</b>	<b>PU</b>
12	11.630	1.260	98,65
13	12.000	720	130,00
14	13.120	500	156,70
15	14.000	1.700	79,50
16	14.700	1.600	86,00
17	15.200	950	111,90
18	15.940	1.460	93,20
19	16.750	1.720	73,80
20	17.470	650	119,30
21	14.800	200	171,00


# Análise Exploratória





# Análise Exploratória



# Análise Exploratória



# Análise Exploratória



# Ajuste do Modelo

```
Call: lm(formula = log(PU) ~ log(A) + log(D), data = zeni_2024a)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	10.95401	0.34272	31.96	< 2e-16 ***
log(A)	-0.36349	0.02901	-12.53	2.50e-10 ***
log(D)	-0.40761	0.03164	-12.88	1.59e-10 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard deviation: 0.07774 on 18 degrees of freedom

Multiple R-squared: 0.9468

F-statistic: 160.2 on 2 and 18 DF, p-value: 3.413e-12

AIC	BIC
-42.92	-38.75



# Aparte: Resíduos Parciais

- Em um modelo de regressão linear, temos:

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k + \varepsilon$$

- Os resíduos totais, portanto, são:

$$\begin{aligned}\hat{\varepsilon} &= Y - (\hat{\beta}_0 + \hat{\beta}_1 X_1 + \cdots + \hat{\beta}_k X_k) \\ \hat{\varepsilon} &= Y - \hat{Y}\end{aligned}$$


- Para obter resíduos parciais em relação a uma variável explicativa, retornamos o efeito dela à equação acima:

- $\hat{\varepsilon}_1 = Y - \hat{Y} + \hat{\beta}_1 X_1$
- $\hat{\varepsilon}_2 = Y - \hat{Y} + \hat{\beta}_2 X_2$
- ...
- $\hat{\varepsilon}_k = Y - \hat{Y} + \hat{\beta}_k X_k$



# Plotagem do Modelo

- Os resíduos parciais são úteis para serem plotados contra as variáveis explicativas:



# Novo Modelo

```
Call: lm(formula = log(PU) ~ log(A) + D, data = zeni_2024a)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	8.54331250	0.18625876	45.87	< 2e-16 ***
log(A)	-0.34773547	0.02029311	-17.14	1.36e-12 ***
D	-0.00049622	0.00002621	-18.93	2.48e-13 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard deviation: 0.05436 on 18 degrees of freedom

Multiple R-squared: 0.974

F-statistic: 337 on 2 and 18 DF, p-value: 5.453e-15


AIC	BIC
-57.95	-53.77

- Note-se o aumento do grau de ajuste do modelo!



# Plotagem do Novo Modelo

Gráficos de Resíduos Parciais



# Centralização dos Dados

- $A = 11.000$  (mediana da variável Área)
- $D = 980$  (moda da variável Distância)

## Modelo Centralizado

```
Call: lm(formula = log(PU) ~ log(A/11000) + I(D - 980), data = zeni_2024a)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	4.82110852	0.01259858	382.67	< 2e-16 ***
log(A/11000)	-0.34773547	0.02029311	-17.14	1.36e-12 ***
I(D - 980)	-0.00049622	0.00002621	-18.93	2.48e-13 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard deviation: 0.05436 on 18 degrees of freedom

Multiple R-squared: 0.974

F-statistic: 337 on 2 and 18 DF, p-value: 5.453e-15

AIC	BIC
-57.95	-53.77

- $\overline{PU}_{Hom} = \exp(4,82) \approx \text{R\$ } 124,0/m^2$



# Derivação de Fatores

- Fator Área ( $F_S$ ):
- $F_S = (11.000/A)^{0,35}$
- Qual o valor de um lote com  $10.000m^2$  situado a uma distância de 100m?
- Previsão a partir dos fatores:
- $F_S = (11.000/A_i)^{0,35}$
- $F_S = (11.000/10.000)^{0,35}$
- $F_D = 0,9995^{(D_i-980)}$
- $F_D = 0,9995^{(100-980)}$
- $\widehat{PU} = \overline{PU}_{Hom} \cdot F_S \cdot F_D$
- $\widehat{PU} = 124,0 \cdot 1,034 \cdot 1,55$
- $\widehat{PU} \approx R\$ 200,0/m^2$
- Fator Distância ( $F_D$ ):
- $F_D = \exp(-5.10^{-3}(D - 980)) = 0,9995^{(D-980)}$
- Previsão a partir do modelo:
- $\ln(\widehat{PU}) = 4,82 - 0,35 \ln(,91) - 5.10^{-3}.880$
- $\ln(\widehat{PU}) = 5,29$
- $\widehat{PU} \approx \exp(5,30)$
- $\widehat{PU} \approx R\$ 200,0/m^2$
- OK!





# Outros tipos de variáveis explicativas

# Outras variáveis

- Variáveis dicotômicas
  - As variáveis dicotômicas são variáveis do tipo 0/1
    - Usualmente: não (0)/ sim (1)
    - Exemplo:
      - Prédio com elevador? não/sim (0/1)
- As variáveis dicotômicas não sofrem transformações
- Um modelo que inclui uma variável dicotônica ( $X_2$ ) será do tipo:
  - $\ln(PU) = \beta_0 + \beta_1 \ln(X_1) + \beta_2 X_2 + \varepsilon$



## Outras variáveis (2)

- Um modelo que inclui uma variável dicotômica ( $X_2$ ) será do tipo:

- $\ln(PU) = \beta_0 + \beta_1 \ln(X_1) + \beta_2 X_2 + \varepsilon$

- Portanto, a sua equação de estimação será:

- $P\hat{U} = \exp(\hat{\beta}_0) \cdot X_1^{\hat{\beta}_1} \cdot \exp(\hat{\beta}_2 \cdot X_2)$

- Como  $\exp(k \cdot X) = \exp(k)^X \rightarrow \exp(\hat{\beta}_2 \cdot X_2) = \exp(\hat{\beta}_2)^{X_2}$ , então:

- $PU = \exp(\hat{\beta}_0) \cdot X_1^{\hat{\beta}_1} \cdot \exp(\hat{\beta}_2)^{X_2}$

- Ou seja, se:

- $X_2 = 0 \rightarrow \exp(\hat{\beta}_2)^{X_2} = \exp(\hat{\beta}_2)^0 = 1$

- $X_2 = 1 \rightarrow \exp(\hat{\beta}_2)^{X_2} = \exp(\hat{\beta}_2)^1 = \exp(\hat{\beta}_2)$



# Outras variáveis (3)

- No caso de variáveis numéricas contínuas, sem transformação, tais como:
  - Quartos ( $Q$ ), com valores possíveis igual a  $\{1, 2, 3, 4, \dots\}$ ;
  - Vagas de Garagens ( $G$ ), com valores possíveis igual a  $\{0, 1, 2, 3, \dots\}$ ;
  - Padrão Construtivo ( $PC$ ) com códigos alocados ou dicotomia em grupo;
  - Vale o mesmo raciocínio das variáveis dicotômicas!
- Exemplo -  $X_1 = \text{Area}$ ,  $X_2 = \text{Elevador}$ ,  $X_3 = G$ :
  - $$PU = \exp(\hat{\beta}_0) \cdot \exp(\hat{\beta}_2)^{\text{Elevador}} \cdot \exp(\hat{\beta}_3)^G$$
  - Se  $G = 0 \rightarrow \exp(\hat{\beta}_3)^0 = 1$
  - Se  $G = 1 \rightarrow \exp(\hat{\beta}_3)^1 = \exp(\hat{\beta}_3)$
  - Se  $G = 2 \rightarrow \exp(\hat{\beta}_3)^2$
  - Se  $G = n \rightarrow \exp(\hat{\beta}_3)^n$



## Outras variáveis (4)

- E se ao ajustar o modelo RLM for utilizada a transformação  $\sqrt{G}$  (ou  $G^2$ , ou qualquer outra transformação, excetuando-se  $\ln(G)$ ):

- $$PU = \exp(\hat{\beta}_0) + \exp(\hat{\beta}_2)^{\text{Elevador}} + \exp(\hat{\beta}_3)^{\sqrt{G}}$$
- Se  $G = 0 \rightarrow \exp(\hat{\beta}_3)^{\sqrt{0}} = 1$
- Se  $G = 1 \rightarrow \exp(\hat{\beta}_3)^{\sqrt{1}} = \exp(\hat{\beta}_3)$
- Se  $G = 2 \rightarrow \exp(\hat{\beta}_3)^{\sqrt{2}} = \exp(\hat{\beta}_3)^{1,414}$
- Se  $G = n \rightarrow \exp(\hat{\beta}_3)^{\sqrt{n}} = \exp(\hat{\beta}_3)^{1,732}$



# Outras variáveis (5)

- Para a dicotomia em grupo, vale tudo que se aplica à dicotomia simples:
  - Não cabem transformações das variáveis dicotômicas em grupo!
  - Os fatores serão obtidos através da exponenciação dos coeficientes
  - A variável passa a ser expoente de  $\exp(\hat{\beta}_i)$



# Outras variáveis (6)

- Assim como é comum utilizar variáveis dicotômicas para testar a alteração dos níveis de preços entre um período e outro, ou entre um bairro e outro, etc.
- É possível utilizar a *dicotomia em grupo* para testar a alteração dos níveis de preços entre 3 ou mais períodos, ou 3 ou mais bairros, etc.
- Na dicotomia em grupo são criadas  $g - 1$  variáveis para simular os  $g$  grupos existentes.
  - Quanto há apenas 2 grupos, cria-se apenas uma variável e a dicotomia em grupo degenera para a dicotomia simples
  - Quando há 3 grupos, deve-se criar 2 variáveis dicotômicas
  - Quando há 4 grupos, deve-se criar 3 variáveis dicotômicas
  - Etc.



# Outras variáveis (7)

- Na dicotomia em grupo, portanto, teremos  $g - 1$  coeficientes que medem a diferença de preços entre o grupo de referência e o grupo em análise.
- Por exemplo:
  - A variável  $PC$  representa o Padrão Construtivo, com 3 níveis:
    - $B$  para Padrão Baixo;
    - $M$  para Padrão Médio;
    - $A$  para Padrão Alto.
  - O nível de referência pode ser qualquer um dos três níveis. Por exemplo, se escolhemos como referência o nível  $B$ , teremos duas variáveis explicativas:
    - $PCM$ , que irá representar os imóveis de Padrão Médio e;
    - $PCA$ , que irá representar os imóveis de Padrão Alto;
- Na matriz do modelo, estas duas variáveis serão dicotômicas (0/1).



# Outras variáveis (8)

- Ex. (Zilli 2020):

```
(Intercept) PCMédio PCAlto NG DABM AP  
1           1      0      1  1  367 97  
2           1      1      0  2  807 73  
3           1      1      0  2  803 120  
4           1      0      1  1  136 122  
5           1      1      0  1  116 110  
6           1      0      0  1  143  84  
7           1      1      0  1  319  95  
8           1      0      1  1  892  54  
9           1      1      0  2  585 138  
10          1      1      0  1  660  60  
11          1      0      1  2  282  96  
12          1      1      0  2  475 120  
13          1      0      1  1  338 120  
14          1      0      1  3  528 167  
15          1      1      0  1  358  67  
16          1      1      0  2  674 109  
17          1      0      1  1   91 110  
18          1      0      1  2  330 159
```

```
Call: lm(formula = PU ~ PC + NG + DABM + AP, data = Zilli2020)  
  
Coefficients:  
              Estimate Std. Error t value Pr(>|t|)  
(Intercept) 5661.9162   404.4109 14.000 < 2e-16 ***  
PCMédio     1575.5161   285.8764  5.511 9.97e-08 ***  
PCAlto      3359.2442   305.4220 10.999 < 2e-16 ***  
NG          1709.5457   191.6150  8.922 < 2e-16 ***  
DABM        -1.1247    0.2157 -5.214 4.26e-07 ***  
AP          -12.0010   3.0807 -3.896 0.00013 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
  
Residual standard deviation: 1538 on 219 degrees of freedom  
Multiple R-squared:  0.6741  
F-statistic: 90.61 on 5 and 219 DF,  p-value: < 2.2e-16  
AIC          3948.68  
BIC          3972.60
```

- Coeficientes das variáveis dicotômicas representam a diferença entre o *PU* do *PC* de referência (Baixo) em relação aos *PCM* e *PCA*!



# Exemplo 2




# Dados

<b>id</b>	<b>PT</b>	<b>PU</b>	<b>AP</b>	<b>PC</b>	<b>NG</b>	<b>NB</b>	<b>ND</b>	<b>NS</b>	<b>MO</b>	<b>PSN</b>	<b>CH</b>	<b>DABM</b>	<b>DSBM</b>
1	920.045	9.485	97	Alto	1	3	3	1	MO	Sim	Sim	367	876
2	699.997	9.589	73	Médio	2	3	2	2	N	Sim	Sim	807	1.266
3	750.000	6.250	120	Médio	2	4	2	2	N	Nao	Nao	803	1.324
4	1.149.972	9.426	122	Alto	1	3	3	1	SM	Nao	Nao	136	1.064
5	700.040	6.364	110	Médio	1	2	3	1	MO	Nao	Nao	116	936
6	630.000	7.500	84	Baixo	1	2	2	0	N	Nao	Nao	143	1.668
7	839.990	8.842	95	Médio	1	2	3	1	MO	Sim	Sim	319	2.615
8	530.010	9.815	54	Alto	1	1	3	0	MO	Nao	Nao	892	1.971
9	1.075.020	7.790	138	Médio	2	4	3	1	MO	Nao	Nao	585	1.291
10	529.980	8.833	60	Médio	1	2	2	1	MO	Nao	Nao	660	1.164




# Análise Exploratória



- Reparem na relação entre *PU* e *AP*!



# Análise Exploratória



- Reparem na relação entre  $\ln(PU)$  e AP!



# Ajuste do Modelo RLM

```
Call: lm(formula = log(PU) ~ PC + I(NG - 1) + I(DABM - 100) + I(AP - 100), data = Zilli2020)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	8.66956323	0.03183323	272.343	< 2e-16 ***
PCMédio	0.26553039	0.03272877	8.113	3.51e-14 ***
PCAlto	0.46075089	0.03496646	13.177	< 2e-16 ***
I(NG - 1)	0.20003869	0.02193718	9.119	< 2e-16 ***
I(DABM - 100)	-0.00016208	0.00002469	-6.564	3.75e-10 ***
I(AP - 100)	-0.00169759	0.00035270	-4.813	2.77e-06 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard deviation: 0.1761 on 219 degrees of freedom


Multiple R-squared: 0.7224

F-statistic: 114 on 5 and 219 DF, p-value: < 2.2e-16

AIC	BIC
-135.09	-111.18



# Plotagem do Modelo



- Reparem em como a relação entre  $AP$  e  $\ln(PU)$  se modificou!



# Derivação do Fator PC

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	8.66956323	0.03183323	272.343	< 2e-16 ***
PCMédio	0.26553039	0.03272877	8.113	3.51e-14 ***
PCAlto	0.46075089	0.03496646	13.177	< 2e-16 ***
I(NG - 1)	0.20003869	0.02193718	9.119	< 2e-16 ***
I(DABM - 100)	-0.00016208	0.00002469	-6.564	3.75e-10 ***
I(AP - 100)	-0.00169759	0.00035270	-4.813	2.77e-06 ***
---				
Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'
	1			

Residual standard deviation: 0.1761 on 219 degrees of freedom

Multiple R-squared: 0.7224

F-statistic: 114 on 5 and 219 DF, p-value: < 2.2e-16

AIC	BIC
-135.09	-111.18

- $\exp(\hat{\beta}_{PCM}) = \exp(0,2655) \approx 1,30$
- $\exp(\hat{\beta}_{PCA}) = \exp(0,46075) \approx 1,59$
- $$F_{PC} = \begin{cases} 1,00 & \text{se } PC = \text{Baixo} \\ 1,30 & \text{se } PC = \text{Médio} \\ 1,59 & \text{se } PC = \text{Alto} \end{cases}$$



# Paradoxo de Simpson



# Paradoxo de Simpson

- Como vimos no exemplo anterior:
  - A relação entre PU e AP era uma relação fraca e positiva!
  - Porém, com o ajuste da *RLM*, essa relação tornou-se negativa e relevante!
- Correlações Parciais:

	Zero-order	Partial	Part
PCMédio	-0,12	0,48	0,29
PCAlto	0,66	0,67	0,47
I(NG - 1)	0,56	0,52	0,32
I(DABM - 100)	-0,47	-0,41	-0,23
I(AP - 100)	0,23	-0,31	-0,17

- Na tabela acima são vistas a correlação de ordem zero, a parcial e a semi-parcial (coluna *Part*).



# Correlações Parciais

Variable	Correlations		
	Zero Order	Partial	Part
PCMédio	-0.119	0.481	0.289
PCAlto	0.658	0.665	0.469
I(NG - 1)	0.564	0.525	0.325
I(DABM - 100)	-0.467	-0.405	-0.234
I(AP - 100)	0.228	-0.309	-0.171

- O valor da correlação semi-parcial elevado ao quadrado é também conhecido como **coeficiente de determinação parcial!**
- Para a variável AP:  $sr_{AP}^2 = (-0,171)^2 \approx 0,03$ .
- Para a variável DABM:  $sr_{DABM}^2 = (-0,234)^2 \approx 0,05$ .
- Para a variável NG:  $sr_{NG}^2 = (-0,325)^2 \approx 0,10$ .
- O coeficiente de determinação parcial de uma variável representa o percentual de explicação que ela **adiciona** ao modelo!



# Correlações Parciais

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	8.66495481	0.03338334	259.559	< 2e-16 ***
PCMédio	0.26618718	0.03433772	7.752	3.32e-13 ***
PCAlto	0.47655274	0.03652368	13.048	< 2e-16 ***
I(NG - 1)	0.14210373	0.01924175	7.385	3.11e-12 ***
I(DABM - 100)	-0.00012863	0.00002486	-5.174	5.16e-07 ***
---				
Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'
	0.1	'	'	1

Residual standard deviation: 0.1848 on 220 degrees of freedom

Multiple R-squared: 0.693

F-statistic: 124.1 on 4 and 220 DF, p-value: < 2.2e-16

AIC	BIC
-114.47	-93.97

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	8.66956323	0.03183323	272.343	< 2e-16 ***
PCMédio	0.26553039	0.03272877	8.113	3.51e-14 ***
PCAlto	0.46075089	0.03496646	13.177	< 2e-16 ***
I(NG - 1)	0.20003869	0.02193718	9.119	< 2e-16 ***
I(DABM - 100)	-0.00016208	0.00002469	-6.564	3.75e-10 ***
I(AP - 100)	-0.00169759	0.00035270	-4.813	2.77e-06 ***
---				
Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'
	0.1	'	'	1

Residual standard deviation: 0.1761 on 219 degrees of freedom

Multiple R-squared: 0.7224


F-statistic: 114 on 5 and 219 DF, p-value: < 2.2e-16

AIC	BIC
-135.09	-111.18

- Acréscimo de  $R^2$  devido à inclusão de  $AP = 0,7224 - 0,6934 \approx 0,03$




# Por que muda a relação entre as variáveis?



# Por que muda a relação entre as variáveis?

- Vejam a relação entre as variáveis explicativas  $AP$  e  $NG$ :



# Por que muda a relação entre as variáveis?

- $\ln(PU) = \beta_{0NG} + \beta_{NG} \cdot NG + \varepsilon_{NG}$
- $\ln(PU) = \beta_{0AP} + \beta_{AP} \cdot AP + \varepsilon_{AP}$
- $\ln(PU) = \beta_{0C} + \beta_{1C} \cdot NG + \beta_{2C} \cdot AP + \varepsilon_C$
- $NG = \beta_{0X} + \beta_{1X} \cdot AP + \varepsilon_X$
- Então:
  - $\ln(PU) = \hat{\beta}_{0C} + \hat{\beta}_{1C}(\hat{\beta}_{0X} + \hat{\beta}_{1X})AP + \hat{\beta}_{2C}AP$
  - $\ln(PU) = (\hat{\beta}_{0C} + \hat{\beta}_{1C}\hat{\beta}_{0X}) + (\hat{\beta}_{1C}\hat{\beta}_{1X} + \hat{\beta}_{2C})AP$
- $\hat{\beta}_{0AP} = \hat{\beta}_{0C} + \hat{\beta}_{1C}\hat{\beta}_{0X}$
- $\hat{\beta}_{AP} = \hat{\beta}_{1C}\hat{\beta}_{1X} + \hat{\beta}_{2C}$



# Por que muda a relação entre as variáveis?

- $\ln(PU) = 8,6225 + 0,303 \cdot NG - 0,00108AP$
- $NG = 0,497 + 0,0094 \cdot AP$
- $\beta_{0AP} = 8,6225 + 0,303 \cdot 0,497 \approx 8,77$
- $\beta_{AP} = 0,303 \cdot 0,0094 + (-0,00108) \approx +0,00177$

```
Call: lm(formula = log(PU) ~ AP, data = Zilli2020)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	8.7729213	0.0568735	154.253	< 2e-16 ***
AP	0.0017783	0.0005083	3.499	0.000564 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard deviation: 0.3225 on 223 degrees of freedom

Multiple R-squared: 0.05204

F-statistic: 12.24 on 1 and 223 DF, p-value: 0.0005641

AIC	BIC
133.20	143.45



# Por que muda a relação entre as variáveis?

- $\ln(PU) = 8,6225 + 0,303 \cdot NG - 0,00108AP$
- $AP = 52,7 + 34,50 \cdot NG$
- $\beta_{0NG} = 8,6225 - 0,00108 \cdot 52,7 \approx 8,565$
- $\beta_{NG} = -0,00108 \cdot 34,50 + 0,303 \approx 0,266$

```
Call: lm(formula = log(PU) ~ NG, data = Zilli2020)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	8.56504	0.04257	201.2	<2e-16 ***
NG	0.26574	0.02607	10.2	<2e-16 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard deviation: 0.2735 on 223 degrees of freedom

Multiple R-squared: 0.3179

F-statistic: 103.9 on 1 and 223 DF, p-value: < 2.2e-16

AIC BIC

59.15 69.39

- Por isso a derivação de fatores através da regressão linear simples entre as variáveis explicativas e a variável independente não funciona!!!



# Exemplo 3




# Dados

- Wooldridge (2019):


PU	price	area	land	year	y81	age	nbh	cbd	inst	rooms	baths	
13,11	60.000	1.660	4.578	1.978	0	48	4	3.000	1.000	7	1	10
4,78	40.000	2.612	8.370	1.978	0	83	4	4.000	1.000	6	2	11
6,80	34.000	1.144	5.000	1.978	0	58	4	4.000	1.000	6	1	11
6,39	63.900	1.136	10.000	1.978	0	11	4	4.000	1.000	5	1	11
4,40	44.000	1.868	10.000	1.978	0	48	4	4.000	2.000	5	1	12
4,84	46.000	1.780	9.500	1.978	0	78	4	3.000	2.000	6	3	10
5,15	56.000	1.700	10.878	1.978	0	22	4	4.000	2.000	6	2	11
9,95	38.500	1.556	3.870	1.978	0	78	4	3.000	2.000	6	2	10
8,64	60.500	1.642	7.000	1.978	0	42	4	3.000	2.000	8	2	10
6,92	55.000	1.443	7.950	1.978	0	41	4	3.000	2.000	5	2	11

# Análise Exploratória




# Análise Exploratória

- Importante: a transformação  $\ln()$  aproxima os dados:



# Análise Exploratória



# Ajuste de modelos

```
Call: lm(formula = log(PU) ~ log(land) + area + cbd + y81 + age + nbh, data =
  hprice3)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	9.548e+00	2.340e-01	40.804	< 2e-16 ***
log(land)	-8.914e-01	2.574e-02	-34.625	< 2e-16 ***
area	3.015e-04	2.039e-05	14.787	< 2e-16 ***
cbd	1.577e-06	2.294e-06	0.688	0.49221
y81	3.506e-01	2.654e-02	13.208	< 2e-16 ***
age	-3.376e-03	4.361e-04	-7.741	1.36e-13 ***
nbh	-1.964e-02	6.306e-03	-3.115	0.00201 **

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard deviation: 0.2277 on 314 degrees of freedom

Multiple R-squared: 0.8983

F-statistic: 462.2 on 6 and 314 DF, p-value: < 2.2e-16

AIC	BIC
-30.23	-0.06




# Diagnóstico do modelo






- Para a estimação de fatores é importante atentar para o bom ajuste do modelo
  - Com um modelo mal ajustado não será possível derivar fatores precisos
  - Algumas ferramentas possibilitam a verificação da linearidade do modelo, por exemplo



# Diagnóstico do modelo



Component + Residual Plots



- A variável *Area* e a variável *Age* parecem pedir transformação!



# Novo modelo

```
Call: lm(formula = log(PU) ~ log(land) + log(area) + cbd + y81 + log1p(age) +
nbh, data = hprice3)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	6.456e+00	3.258e-01	19.813	< 2e-16 ***
log(land)	-8.821e-01	2.404e-02	-36.701	< 2e-16 ***
log(area)	4.970e-01	4.066e-02	12.224	< 2e-16 ***
cbd	-2.097e-06	2.202e-06	-0.952	0.34170
y81	3.599e-01	2.478e-02	14.525	< 2e-16 ***
log1p(age)	-8.930e-02	9.367e-03	-9.533	< 2e-16 ***
nbh	-1.707e-02	5.952e-03	-2.868	0.00441 **

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard deviation: 0.2144 on 314 degrees of freedom

Multiple R-squared: 0.9098


F-statistic: 528 on 6 and 314 DF, p-value: < 2.2e-16

AIC	BIC
-68.83	-38.66

- A variável *cbd* não se mostrou estatisticamente significante!



# Diagnóstico do novo modelo



- As variáveis mais importantes são: *land*, *area*, *age* e *y81*
  - *cbd* e *nbh* são duas variáveis pouco importantes!



# Modelo Final

```
Call: lm(formula = log(PU) ~ log(land) + log(area) + y81 + log1p(age) + nbh,  
        data = hprice3)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	6.528721	0.316575	20.623	< 2e-16 ***
log(land)	-0.897794	0.017509	-51.275	< 2e-16 ***
log(area)	0.504073	0.039980	12.608	< 2e-16 ***
y81	0.361585	0.024707	14.635	< 2e-16 ***
log1p(age)	-0.086262	0.008807	-9.795	< 2e-16 ***
nbh	-0.019047	0.005578	-3.415	0.000722 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard deviation: 0.2143 on 315 degrees of freedom


Multiple R-squared: 0.9096

F-statistic: 633.6 on 5 and 315 DF, p-value: < 2.2e-16


AIC	BIC
-69.9	-43.5




# Diagnóstico do Modelo Final





Component + Residual Plots



$\log(\text{area})$




$y81$




# Diagnóstico do Modelo Final


**Residual Plot**




**Q-Q Plot**



**Index Plot**



**Histogram**




# Aparte: Resíduos Jackknife


- Resíduos *jackknife* são resíduos padronizados que são computados ao realizar um processo de reamostragem conhecido como *jackknife*!
- Grosso modo, o processo funciona da seguinte forma:
  - Retira-se um dado da amostra
  - Ajusta-se um modelo
  - Computa-se o valor previsto com este modelo para o dado excluído da amostra
  - Calcula-se o seu resíduo padronizado deste dado
  - Prossegue-se retirando um dado de cada vez até que todos os dados tenham seus resíduos calculados
- Também são conhecidos como resíduos *studentizados* ( $t_i$ )
- Um bom critério para detecção de *outliers*:  $|t_i| > 3,0$







# Diagnóstico do Modelo Final



# Reajustamento do Modelo Final



# Painel de Resíduos do Modelo Final



# Estatísticas do Modelo Final

```
Call: lm(formula = log(PU) ~ log(land) + log(area) + y81 + log1p(age) + nbh,  
        data = hprice3, subset = -c(37, 46, 52, 67, 93, 157, 168, 229, 230, 259, 303,  
        315))
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	7.058832	0.266793	26.458	< 2e-16 ***
log(land)	-0.928501	0.014185	-65.455	< 2e-16 ***
log(area)	0.481479	0.032656	14.744	< 2e-16 ***
y81	0.354456	0.019689	18.003	< 2e-16 ***
log1p(age)	-0.104942	0.007338	-14.302	< 2e-16 ***
nbh	-0.019478	0.004465	-4.363	0.0000176 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard deviation: 0.1676 on 303 degrees of freedom


Multiple R-squared: 0.9442

F-statistic: 1024 on 5 and 303 DF, p-value: < 2.2e-16

AIC	BIC
-218.92	-192.79




# Centralização do Modelo Final



- Moda: 43.560,00 sqft  $\approx 1\text{ acre} \approx 4046,85\text{m}^2$



# Centralização do Modelo Final



- Moda: 2.464 sqft  $\approx 230m^2$



# Outras variáveis

- y81: 0 (não)
- age: 0 (novo)
- nbh: 0



# Modelo Centralizado

```
Call: lm(formula = log(PU) ~ log(land/43560) + log(area/2464) + y81 +
    log1p(age) + nbh, data = hprice3, subset = -c(37, 46, 52, 67, 93, 157, 168,
    229, 230, 259, 303, 315))
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	0.900808	0.020276	44.427	< 2e-16 ***
log(land/43560)	-0.928501	0.014185	-65.455	< 2e-16 ***
log(area/2464)	0.481479	0.032656	14.744	< 2e-16 ***
y81	0.354456	0.019689	18.003	< 2e-16 ***
log1p(age)	-0.104942	0.007338	-14.302	< 2e-16 ***
nbh	-0.019478	0.004465	-4.363	0.0000176 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard deviation: 0.1676 on 303 degrees of freedom

Multiple R-squared: 0.9442

F-statistic: 1024 on 5 and 303 DF, p-value: < 2.2e-16

AIC	BIC
-218.92	-192.79



# Derivação de Fatores

- $PU_{Hom} = \exp(\hat{\beta}_0^*) = \exp(0,90) \approx 2,46$
- $F_S = \left( \frac{43.560}{S_i} \right)^{0,93}$
- $F_A = \left( \frac{A_i}{2.464} \right)^{0,48}$
- $F_Y = \begin{cases} 1 & \text{se } y_{81i} = 0; \\ \exp(.35) = 1,425 & \text{se } y_{81i} = 1; \end{cases}$
- $F_I = (1 + Age_i)^{-0,105}$
- $F_N = \exp(-0,02)^{nbh_i} = 0,98^{nbh}$



# Aplicação

- Avaliar por fatores:

- $S = 360m^2; A = 100m^2, y_{81} = 1, age = 0, nbh = 6$

- Obs.:  $1m^2 = 10,764 \text{ sqft}$

- Solução pelo modelo:

- $$\ln(\widehat{PU}) = 0,90 - 0,93 \ln(S/43.560) + 0,48 \cdot \ln(A/2.464) + 0,3545 \cdot y_{81} - 0,105 \ln(1 + age) - 0,02 \cdot nbh$$

- $$\ln(\widehat{PU}) = 0,90 - 0,93 \ln(3.875/43.560) + 0,48 \cdot \ln(1.076,4/2.464) + 0,3545 \cdot 1,0 - 0,105 \ln(1 + 0) - 0,02 \cdot 6$$

- $$\ln(\widehat{PU}) = 0,90 + 2,25 - 0,40 + 0,3545 - 0 - 0,12 = 2,9845$$

- $$\widehat{PU} = \exp(2,9845) \approx 19,78 \text{ (US\$/sqft)}$$





96

<http://www.valoristica.com.br>

# Solução por fatores

- $F_S = \left( \frac{43.560}{S_i} \right)^{0,93} = \left( \frac{43.560}{3.875} \right)^{0,93} = 9,49$
- $F_A = \left( \frac{A_i}{2.464} \right)^{0,48} = \left( \frac{1.076,4}{2.464} \right)^{0,48} = 0,67$
- $F_Y = 1,425$
- $F_I = (1 + Age_i)^{-0,105} = (1 + 0)^{-0,105} = 1,0$
- $F_N = 0,98^{nbh} = 0,98^6 = 0,886$
- $\widehat{PU}_i = 2,46 \cdot F_{Si} \cdot F_{Ai} \cdot F_{Y_i} \cdot F_{Ii} \cdot F_{Ni}$
- $\widehat{PU}_i = 2,46 \cdot 9,49 \cdot 0,67 \cdot 1,425 \cdot 1,0 \cdot 0,886$
- $\widehat{PU}_i = 2,46 \cdot 8,03 \approx 19,75 \text{ (US\$/sqft)}$






97

<http://www.valoristica.com.br>

# Análise

Var.	n_missing	%	Mean	SD	P0	P25	P50	P75	P100	Hist.
PU	0	1	3,75	2,97	0,11	1,86	2,92	4,78	25,22	
price	0	1	96.100,66	43.223,73	26.000,00	65.000,00	85.900,00	120.000,00	300.000,00	
area	0	1	2.106,73	694,96	735,00	1.560,00	2.056,00	2.544,00	5.136,00	
land	0	1	39.629,89	39.514,39	1.710,00	16.935,00	43.560,00	46.100,00	544.500,00	
year	0	1	1.979,33	1,49	1.978,00	1.978,00	1.978,00	1.981,00	1.981,00	
y81	0	1	0,44	0,50	0,00	0,00	0,00	1,00	1,00	
age	0	1	18,01	32,57	0,00	0,00	4,00	22,00	189,00	
nbh	0	1	2,21	2,16	0,00	0,00	2,00	4,00	6,00	
cbd	0	1	15.822,43	8.967,11	1.000,00	9.000,00	14.000,00	23.000,00	35.000,00	
inst	0	1	16.442,37	9.033,13	1.000,00	9.000,00	16.000,00	24.000,00	34.000,00	
rooms	0	1	6,59	0,90	4,00	6,00	7,00	7,00	10,00	
baths	0	1	2,34	0,77	1,00	2,00	2,00	3,00	4,00	
dist	0	1	20.715,58	8.508,18	5.000,00	13.400,00	19.900,00	27.200,00	40.000,00	

- Range da Var. *land*: 1.710, 544.500 sqft (159 a 50.585  $m^2$ )
- Range da Var. *area*: 735, 5.136 sqft (68 a 477  $m^2$ )
- Range da Var. *age*: 0, 189 anos



# Referências

- Cerino, Rocío Mariel, Juan Pablo Carranza, Mario Andrés Piumetto, María Emilia Bullano, Federico Monzani, e Mariano Augusto Córdoba. 2020. «Homogeneización del valor de la tierra urbana mediante técnicas de econometría espacial en valuaciones masivas automatizadas». *14º COBRAC*. <https://rdu.unc.edu.ar/handle/11086/28446>.
- Droubi, Luiz Fernando Palin, e Lutemberg de Araújo Florencio. 2024. «Fatores de Homogeneização: Derivação e uso racional». *XXXVIII Congresso Pan-Americano UPAV – CHILE 2024*. <https://www.upavchile2024.com/>.
- Droubi, Luiz Fernando Palin, Carlos Augusto Zilli, e Norberto Hochheim. 2021. «Avaliação de Imóveis à partir de dados de oferta e transação». *XXI COBREAP*.
- Lima, Gilson Pereira de Andrade. 2006. «Homogeneização por Fatores na Forma Aditiva, Multiplicativa ou Mista? Imposição Normativa ou Resposta do Mercado?» *XIII COBREAP*.
- Oliveira, Antônio Augusto Ferreira de, Sandro Ricardo Vasconcelos Bandeira, e Victor Jucá Távora. 2024. «Mass appraisal of urban land with homogenization factors: a spatial models-based approach». *Revista Valorem* 1 (1): 16–32. <https://revistavalorem.com/index.php/home/article/view/23>.
- Trivelloni, Carlos Alberto Peruzzo. 2005. «Método para determinação do valor da localização com uso de técnicas inferenciais e geoestatísticas na avaliação em massa de imóveis». Tese de Doutorado, Florianópolis, SC: Universidade Federal de Santa Catarina.
- Wooldridge, Jeffrey M. 2019. *Introductory Econometrics: A Modern Approach*. 7.<sup>a</sup> ed. Thomson South-Western.
- Zeni, André Maciel. 2024. *Engenharia de Avaliações: Metodologia Científica - Processo Comparativo*. Feedback.
- Zilli, Carlos Augusto. 2020. «Regressão geograficamente ponderada aplicada na avaliação em massa de imóveis urbanos.» Dissertação de mestrado. Florianópolis, SC: Universidade Federal de Santa Catarina.

